Apa yang Sedang Dilakukan Orang-Orang

Penjelasan Aktivitas Saat Ini

[Rio Meidi A] — Apa yang Sedang Dilakukan Sekarang

1. Pengecekan Dataset

- [ ] Memeriksa dataset 2026 yang sudah diunduh.
- [ ] Memastikan bulan yang tersedia dan jumlah file. Jika tersedia Januari–Juli, pastikan seluruh tujuh bulan terwakili.
- [ ] Mencatat ukuran file, jumlah baris, dan jumlah kolom setiap file.
- [ ] Memeriksa rentang waktu `tpep_pickup_datetime` dan `tpep_dropoff_datetime`.
- [ ] Mengidentifikasi seluruh fitur yang tersedia pada dataset 2026.
- [ ] Memeriksa apakah nama kolom dan tipe data konsisten antarbulan.
- [ ] Memeriksa kolom yang seluruh nilainya kosong atau hanya tersedia pada bulan tertentu.
- [ ] Menentukan apakah dataset 2026 sesuai dengan tujuan penelitian.

Output yang diharapkan:

- `reports/tables/00_file_inventory.csv`
- `reports/tables/01_schema_comparison.csv`
- `analysis_plan.md`

2. Dataset Engineering

2.1 Audit Kualitas Dataset

- [ ] **Missing Values**
  - [ ] Menghitung jumlah nilai kosong pada setiap kolom.
  - [ ] Menghitung persentase nilai kosong pada setiap kolom.
  - [ ] Mengidentifikasi kolom yang nilai kosongnya perlu ditangani.
  - [ ] Menentukan strategi penanganan berdasarkan fungsi kolom dan tujuan analisis.
  - [ ] Tidak langsung menghapus baris hanya karena satu kolom memiliki nilai kosong.
- [ ] **Duplicate Values**
  - [ ] Menghitung jumlah duplikat seluruh baris.
  - [ ] Memeriksa apakah duplikat merupakan catatan berulang atau perjalanan berbeda yang kebetulan memiliki nilai serupa.
  - [ ] Menentukan aturan penghapusan duplikat dan mencatat jumlah baris yang dihapus.
- [ ] **Outlier**
  - [ ] Memeriksa distribusi `trip_distance`.
  - [ ] Memeriksa distribusi `fare_amount` dan `total_amount`.
  - [ ] Memeriksa distribusi `passenger_count`.

    - [ ] Memeriksa nilai nol, negatif, atau nilai ekstrem yang tidak masuk akal.
    - [ ] Menandai nilai ekstrem untuk diperiksa sebelum memutuskan apakah perlu dihapus.
    - [ ] Mendokumentasikan batas dan alasan setiap aturan.

- [ ] **Anomaly Detection**

    - [ ] Menghitung jumlah perjalanan per jam dan per hari.
    - [ ] Mengidentifikasi lonjakan atau penurunan jumlah perjalanan yang tidak biasa.
    - [ ] Memeriksa timestamp yang berada di luar periode dataset yang dipilih.
    - [ ] Memeriksa durasi perjalanan yang negatif atau tidak masuk akal.
    - [ ] Membedakan kesalahan pencatatan dari kejadian nyata.
    - [ ] Mendokumentasikan anomali yang ditemukan dan keputusan penanganannya.

- [ ] **Validasi Timestamp**

    - [ ] Memastikan kolom pickup dan dropoff terbaca sebagai tipe datetime.
    - [ ] Memeriksa timestamp kosong atau tidak valid.
    - [ ] Menghitung durasi perjalanan dari waktu pickup dan dropoff.
    - [ ] Memeriksa perjalanan dengan waktu dropoff sebelum waktu pickup.
    - [ ] Memastikan seluruh data berada pada rentang waktu penelitian.

- [ ] **Validasi Nilai dan Kategori**

    - [ ] Memeriksa nilai ID lokasi yang kosong atau tidak dikenal, jika kolom tersedia.
    - [ ] Memeriksa kode kategori seperti `VendorID`, `RatecodeID`, dan `payment_type`.
    - [ ] Memeriksa nilai finansial yang tidak masuk akal.
    - [ ] Memastikan satuan setiap atribut dipahami sebelum dipakai.

Output yang diharapkan:

- `reports/tables/02_data_quality.csv`
- `reports/tables/03_cleaning_log.csv`
- Grafik dan catatan hasil pemeriksaan kualitas data.

2.2 Menentukan Aturan Data Cleaning

- [ ] Membuat daftar aturan cleaning sebelum diterapkan.
- [ ] Menentukan kolom yang wajib tersedia untuk analisis.
- [ ] Menentukan penanganan missing values untuk tiap kolom.
- [ ] Menentukan aturan penghapusan duplikat.
- [ ] Menentukan batas nilai tidak valid berdasarkan logika perjalanan dan dokumentasi.
- [ ] Memastikan aturan outlier tidak menghapus perjalanan yang sebenarnya valid.
- [ ] Menyimpan dataset mentah tanpa perubahan di folder `data/raw/`.
- [ ] Menyimpan hasil cleaning secara terpisah di folder `data/interim/` atau `data/processed/`.
- [ ] Mencatat jumlah baris sebelum dan sesudah setiap aturan.
- [ ] Menghitung persentase baris yang dihapus pada setiap langkah.
- [ ] Memeriksa apakah penghapusan data terkonsentrasi pada tanggal atau periode tertentu.

Template log cleaning:

Aturan	Baris sebelum	Baris dibuang	Baris sesudah	Alasan
Data di luar rentang waktu				
Timestamp tidak valid				
Missing values sesuai aturan				
Duplikat seluruh baris				
Nilai perjalanan tidak valid				
Aturan lainnya				

2.3 Penanganan `PULocationID` dan `DOLocationID`

- [ ] Memastikan apakah dataset yang dipilih menggunakan koordinat GPS atau ID zona.
- [ ] Memahami bahwa `PULocationID` merupakan ID zona pickup dan `DOLocationID` merupakan ID zona dropoff.
- [ ] **Tidak mengganti ID zona dengan longitude/latitude secara langsung**, karena ID zona bukan koordinat geografis.
- [ ] Jika dataset 2026 digunakan, memeriksa kebutuhan *Taxi Zone Lookup Table* untuk memperoleh nama zona dan borough.
- [ ] Jika analisis membutuhkan geometri zona, mengevaluasi penggunaan *Taxi Zone Shapefile*.
- [ ] Jika menggunakan centroid zona, memberi nama kolom yang jelas, misalnya `PU_centroid_longitude`, `PU_centroid_latitude`, `DO_centroid_longitude`, dan `DO_centroid_latitude`.
- [ ] Menjelaskan bahwa centroid hanya mewakili perkiraan pusat zona, bukan lokasi pickup/dropoff GPS yang sebenarnya.
- [ ] Mempertahankan kolom ID zona sebagai referensi untuk analisis perjalanan antarzona.
- [ ] Menetapkan representasi lokasi berdasarkan tujuan clustering dan ketersediaan data.

Keputusan yang perlu dicatat:

Pilihan	Kapan digunakan	Catatan
ID zona	Analisis pickup/dropoff dan perjalanan antarzona	Pertahankan ID asli
Nama zona/borough	Analisis agregat berdasarkan wilayah	Perlu lookup table
Centroid zona	Visualisasi atau pendekatan spasial berbasis titik	Bukan koordinat perjalanan sebenarnya
Koordinat GPS asli	Clustering berdasarkan lokasi perjalanan yang presisi	Hanya jika koordinat benar-benar tersedia

2.4 Feature Engineering

- [ ] Menentukan fitur yang diperlukan berdasarkan tujuan analisis.
- [ ] Membuat fitur waktu dari `tpep_pickup_datetime`, jika diperlukan:

    - [ ] `pickup_hour`
    - [ ] `day_of_week`
    - [ ] `is_weekend`
    - [ ] `day_index`
- [ ] Menghitung `trip_duration` dari waktu dropoff dikurangi waktu pickup.
- [ ] Memastikan durasi yang tidak valid ditangani sesuai aturan cleaning.
- [ ] Menentukan fitur spasial berdasarkan data yang tersedia: koordinat GPS, ID zona, atau centroid zona.
- [ ] Menentukan fitur target untuk forecasting, misalnya jumlah pickup per jam.
- [ ] Menyusun kamus fitur berisi nama, tipe data, definisi, dan tujuan penggunaan.
- [ ] Menghindari fitur yang tidak relevan atau menyebabkan kebocoran informasi (*data leakage*).

Output yang diharapkan: `feature_dictionary.md`

3. Exploratory Data Analysis (EDA)

- [ ] Menghitung jumlah perjalanan per bulan.
- [ ] Membuat grafik jumlah perjalanan per jam.
- [ ] Membuat grafik jumlah perjalanan per hari.
- [ ] Membandingkan pola perjalanan pada hari kerja dan akhir pekan.
- [ ] Memeriksa distribusi jarak perjalanan.
- [ ] Memeriksa distribusi durasi perjalanan.
- [ ] Memeriksa distribusi tarif.
- [ ] Menganalisis zona pickup dan dropoff yang paling sering muncul, jika ID zona tersedia.
- [ ] Membuat visualisasi spasial yang sesuai dengan jenis lokasi yang tersedia.
- [ ] Membandingkan distribusi sebelum dan sesudah cleaning.
- [ ] Mencatat temuan utama dan pertanyaan lanjutan dari setiap visualisasi.

Output yang diharapkan:

- Notebook EDA.
- Grafik distribusi dan pola waktu.
- Grafik atau peta spasial jika data mendukung.
- Ringkasan temuan awal.

4. Persiapan Analisis Lanjutan

- [ ] Menentukan apakah data cocok untuk clustering.
- [ ] Menentukan apakah data cocok untuk forecasting.
- [ ] Menetapkan unit analisis, misalnya perjalanan, zona, atau zona × jam.
- [ ] Menentukan target dan fitur untuk model.
- [ ] Menentukan skema validasi berbasis waktu jika melakukan forecasting.
- [ ] Menyusun daftar eksperimen dan metrik evaluasi.
- [ ] Memastikan keputusan metodologi terdokumentasi sebelum pemodelan.

---

5. Struktur Folder yang Disarankan

```
nyc-taxi-project/
├── README.md
├── analysis_plan.md
├── data/
│   ├── raw/                  # Data asli, tidak diubah
│   ├── interim/              # Data setelah tahap pengolahan antara
│   ├── processed/            # Data bersih yang siap dianalisis
│   └── external/             # Lookup table, shapefile, atau data eksternal
├── notebooks/
│   ├── 01_dataset_inventory.ipynb
│   ├── 02_data_quality_audit.ipynb
│   ├── 03_data_cleaning.ipynb
│   └── 04_eda.ipynb
├── reports/
│   ├── figures/
│   └── tables/
└── docs/
    └── feature_dictionary.md
```

> Sesuaikan struktur folder dengan struktur repositori yang sudah ada. Jangan menggandakan file besar tanpa kebutuhan.

---

6. Urutan Prioritas Pengerjaan

Prioritas 1 — Harus selesai terlebih dahulu

- [ ] Memastikan dataset dan periode penelitian.
- [ ] Memastikan seluruh file dan bulan yang tersedia.
- [ ] Membandingkan skema kolom.
- [ ] Membuat inventaris file.
- [ ] Menghasilkan laporan missing values, duplikat, dan rentang waktu.

Prioritas 2 — Sebelum cleaning

- [ ] Menetapkan aturan missing values.
- [ ] Menetapkan aturan duplikat.
- [ ] Menetapkan kriteria outlier dan anomali.
- [ ] Menentukan cara menangani `PULocationID` dan `DOLocationID`.
- [ ] Membuat log perubahan dan penghapusan baris.

Prioritas 3 — Sebelum pemodelan

- [ ] Menyelesaikan cleaning dan memvalidasi hasilnya.
- [ ] Menyusun feature dictionary.
- [ ] Menyelesaikan EDA.
- [ ] Menetapkan unit analisis dan target model.
- [ ] Mendokumentasikan metodologi final.

---

7. Kriteria Selesai Tahap Awal (*Definition of Done*)

Tahap awal dapat dianggap selesai apabila:

- ☐ Dataset dan periode penelitian telah diputuskan dengan alasan yang jelas.
- ☐ Semua file yang akan digunakan telah terinventarisasi.
- ☐ Struktur kolom dan tipe data telah diperiksa.
- ☐ Kualitas data telah diringkas dalam laporan.
- ☐ Aturan cleaning telah ditulis dan dapat diulang.
- ☐ Jumlah baris yang dihapus pada setiap tahap tercatat.
- ☐ Representasi lokasi telah ditentukan dan dijelaskan.
- ☐ Fitur yang akan dibuat telah didokumentasikan.
- ☐ EDA awal telah dilakukan dan temuan utamanya dicatat.
- ☐ Data mentah tetap tersimpan tanpa perubahan.

---

8. Catatan Keputusan yang Belum Final

- ☐ Dataset final: 2016 / 2026.
- ☐ Rentang bulan yang digunakan: ******___******.
- ☐ Tujuan utama penelitian: ******___******.
- ☐ Representasi lokasi: ID zona / centroid zona / koordinat GPS.
- ☐ Unit analisis: perjalanan / zona / zona × jam / lainnya.
- ☐ Model yang akan diuji: ******___******.
- ☐ Metrik evaluasi: ******___******.
- ☐ Alasan perubahan metodologi, jika ada: ******___******.

Catatan: jangan menganggap suatu aturan atau ambang cleaning sudah final sebelum memeriksa distribusi data dan menuliskan alasan pemilihannya.